苏轼与辛弃疾词作者归因：一个部署逻辑回归的文本分类器

1. 研究问题

本研究实施一项二元文本分类训练，目的在于断定一首宋词系苏轼（1037 – 1101）作品还是辛弃疾（1140 – 1207）之作，此类即作者归因研究课题：接收一段文稿，依据用词偏好识别作者。

确立苏辛为研究样本因两方面因素，二人同列宋词“豪放派”之行列，所以惯被称作“苏辛”，然而其文体风格、用语规律与情感传递实具系统层面的分歧，作者归属问题构成计算人文之基础议题，从文学史层面观照，我们拟检验一个预设：即便作者同列一文学流派，其遣词特征是否依旧可经统计量化工分？此类辨析又关联着怎样的根本动因?

这个问题的重要性在于：它将文学史内不定的“风格差异”映射为可运算的信号，假如模型可高概率分辨苏辛，证实双方用词习惯具有结构性的不同特征；一旦模型判定失败，则证实"豪放派"内部风格范围较预料更趋不明。

2. 标签定义与数据来源

2.1 标签定义

- 标签 0：苏轼，存世苏轼词作文本。

- 标签 1：辛弃疾，现有文本属于辛弃疾存世词作范畴。

文本单位是一首完整的词：去掉词牌名称及标题，使正文全部段落合成"一个字"符串，之所以核“一首词”而非“一句”或“一字”作为参照单位，缘于词作长度（普遍在60 – 100字左右）具备承载充分用词信号的能力，又不至让作者的用词规律失去辨识度。

2.2 数据来源

依据来自开源中文诗词资源库 [chinese-poetry](https:基于 chinese-poetry 数据集（URL: g.m/chinese-poetry/chinese-poetry），该库收录全宋词约21,按创作者予以区分，获选苏轼与辛弃疾的词作各352首进行统计，包含700条样本（实核352+352=704条），两类样本总量完全相当，规避类别分布不均对评估的干扰。

数据被组织为CSV格式，各行均设两列内容：`text`（词体文本）和 `label`（0 系苏轼，1=辛门大家。

3. 数据处理与特征

3.1 中文分词

空格充当了英文文本直接分词的界限，然而中文无天然形成的分词界线，基于此引入 jieba 分词库，对词作正文实施分词操作，诸如“雨后春容清更丽”被解析为“雨后/春容清/更丽/"，"。

3.2 特征提取：TF-IDF

本作业比较了三种特征方案：主要词汇的词频、TF-IDF 参数和 z-score 标准化后频率，最终基于TF-IDF（Term Frequency – Inverse Document Frequency）开展分析，理由如下：

纯粹基于词频的分析容易使“的”“了”“是”等无区分力的高频虚词占据主导；

- TF-IDF 兼顾了词汇在一首词中出现频率这一维度，进而降低在全局范围内高频分布词的权重，使拥有强判别特征的词项（像苏轼惯用的“清风”“明月”），致使辛弃疾惯用的“西北”“神州”得到更高权重；

- 比之于 z-score，就文本分类而言，TF-IDF一般呈现出更为恒定的特性。

具体参数：实施max_features截取200，也就是从训练集里筛选出最具信息价值的200个词汇构成特征，此系人为设定的简化处理——使用200词即可，既收敛了模型复杂度，也落实“思考你的特征”作业的任务目标。

3.3 训练集与测试集切分

以80%/20%为基准对704条样本分层截断：训练集中有563条（苏轼281，辛弃疾条目282个，测试集收录141条（苏轼71），辛作样本70），利用 `stratify=y` 参数保障训练及测试数据中各类别占比相同，实施 random_state=42 以约束随机种子，落实研究的可复现要求。

4. 模型训练与评估

4.1 模型

依托 scikit-learn 开发的 `LogisticRegression`（逻辑回归）方法，约束迭代过程至1000次以保证收敛，逻辑回归纳入线性分类方法的体系之中，以TF-IDF特征向量为输入，输出涉及两类词汇的概率分布。

4.2 测试集结果

针对141条测试记录的指标测算：

指标

数值

准确率 Accuracy

0.7801

精确率 Precision

0.7826

召回率 Recall

0.7714

F1 分数

0.7770

混淆矩阵:

预测：苏轼

预测：辛弃疾

实际：苏轼

56

15

**实际：辛弃疾

16

54

测试集上模型取得了78%的识别准确率，极大优于随机推断的

50%标准，这说明：仅基于200个词的TF-IDF指标，逻辑回归足以说明苏辛之间系统性的用语不同。

4.3 哪些词最能区分两人

模型所获特征权重揭示，针对苏辛两家的词作表现出根本性的语义不同，苏轼词作中高频的自然风物、闲适日常与清风明月，同辛弃疾词里鲜明的历史人物、战争叙事、家国情怀及西北意象呈现出截然不同之势，此类分野同文学史已有观察一致：苏轼词作更落脚于个体的自然感兴，辛弃疾词作多呈现英雄失路之悲慨长调风貌。

5. 错误分析

就141首入样词作而言，其中31条归类有误：15首苏轼词作被误认作辛弃疾，另有16首辛弃疾作品错判作苏轼。

误分类之因可析为两大类：

1. 风格重叠：个别文本不囿于豪放或婉约单一，其用语既不类典型苏轼也不类典型辛弃疾，如苏轼一些酬酢之篇，笔调上接近辛弃疾的激昂，而辛词中部分写景篇什也趋苏轼清旷之境，200词的样本量不足以使模型识别这种细微区别。

2. 短文本信号不足：一些词汇截面较窄，词汇使用平常，缺少辨识度词汇，造成模型缺乏做出判断的足够依据。

这说明：虽然准确率达到78%尚可，然而模型未得“风格”精髓——依赖支点仍囿于表层词汇的统计数值，而非深层的底层范式。

6. 应用：李清照词的作者归因

已获训练的模型被部署至一批“自选文本”：李清照（1084 – 约1155）的五种词作，李清照乃大宋著名闺秀词人，不隶属豪放一脉，使模型介入其词作分析，相当于开展一项“迁移测试”：模型所识的苏辛用词分界，针对陌生作者群体将形成怎样的决策？

词牌

模型预测

苏轼概率

辛弃疾概率

如梦令 · 昨夜雨疏风骤

辛弃疾

0.336

0.665

一剪梅 · 红藕香残玉簟秋

苏轼

0.563

0.437

声声慢 · 寻寻觅觅

辛弃疾

0.161

0.839

武陵春 · 风住尘香花已尽

辛弃疾

0.216

0.784

夏日绝句

苏轼

0.649

0.351

几个值得讨论的发现：

1. 五首词作有四首被认定为辛弃疾所填，就总体用词而言，李清照风貌类同辛弃疾，考虑到李清照词作大量呈现悲秋、伤逝及怀旧意象，辛作之中也多见相类母题（诸如“暮春”“落花”“登临”），前述主题词在TF-IDF特征空间里处于高权重地位。

2. 《声声慢》检出率位列第一（84%），开篇叠语（“寻寻觅觅，冷冷清清，凄凄惨惨戚戚”）在此处起到了奠定基调的作用，此词肃杀的悲秋意境被模型显著划归辛弃疾一类，这说明：模型对“悲秋”类语汇的感知十分敏锐。

3. 《夏日绝句》被误植作者为苏轼（65%），该文本载“生当作人杰”，死亡不改鬼雄身份，至今思及项羽，不肯临江而渡流露慷慨风格，按直接体认当属辛弃疾一脉，然而模型却判定属于苏轼，

从另一角度考量：诗中“人杰”“鬼雄”及“项羽”等术语，在辛弃疾词里出现的次数不多，而苏轼词作内或存有关联的咏史怀古言说，使得模型出现错判，这说明模型判别尚有短板——依托于词汇统计机制，不能把握诗歌的情感张力。

4. 概率分布阐明了不确定性，《一剪梅》的概率落至0.5（56%苏轼），说明模型对该词的分析结论带有较高的不确定，这映照出我们：不应不加审视便全盘接纳模型标注结果，故而要融合概率分布来审视模型的置信特征。

7. 局限与改进

本研究存在以下局限：

1. 特征维度有限：仅基于200个词的TF-IDF，句法结构、词序与韵律等信息被模型所忽略，后续可拓展至n-gram（二元或三元组）及字符级特征的应用，还可嵌入预训练词向量技术（比如Word2Vec）。

2. 数据量较小：每类实有352首词，扩大数据集范围至全宋豪放派词人，将有利于形成更稳定的分类决策边界。

3. 分词误差：jieba 针对古汉语的切分准确度不高，某些词语或引错切，引入噪声。

4. 线性模型的局限：逻辑回归构成线性分类的一种形式，受制于确立词汇和标签的线性关联，难以拟合高维交互作用，拟进一步尝试朴素贝叶斯、支持向量机与基础神经网络模型。

5. 不应过度解读模型输出：模型针对李清照词所作的剖析印证了词汇统计的相像，而非本真的“风格认同”，李清照并非苏轼以及

辛弃疾，模型分析仅指出其行文用语在若干方面更趋向于哪一极。

8. 结论

本作业运用TF-IDF特征和逻辑回归方法开发了二元分类器，用以判别苏轼和辛弃疾的诗词，在704条样本基础上，模型于测试集中实现78%的准确率，阐明苏辛二人拥有系统性的用词区别，对李清照的词应用该模型，结果显示模型整体将其划归辛弃疾一类，而此结论应作审慎解读——直指词汇结构的统计相近，而非行文气质实质的精准认定，本研究阐明了文本分类技术对文学探究的重要价值，也昭显我们：模型技术可评估风格不同，却不可越俎代庖以微观检视与人文理解。